

February 24, 2025

1 Trabajo Final MD004

2 PARTE I

Imaginemos que trabajas en una empresa de análisis de datos para una compañía de transporte público que opera una flota de autobuses en Barcelona. Debes desarrollar un modelo predictivo para estimar el consumo de combustible de los autobuses en función de diferentes variables. Dispones de un conjunto de datos que incluye 35 variables explicativas (31 continuas y 4 categóricas) El dataset que te hacen llegar contiene información recopilada de sensores instalados en los autobuses, así como datos operativos y ambientales. A continuación, se presenta un ejemplo de las variables presentes en el conjunto de datos Ejemplo variables continuas: • Distancia recorrida desde el último repostaje (en kilómetros) • Velocidad media del autobús durante el trayecto (en kilómetros por hora) • Carga promedio de pasajeros a bordo • Temperatura exterior durante el trayecto (en grados Celsius) • Año de fabricación del autobús Variables categóricas: • Tipo de motor del autobús (convencional, eléctrico, híbrido) • Ruta del autobús (urbana, interurbana) • Tramo de la semana (fin_de_semana, no_fin_de_semana) • Condiciones climáticas (soleado, nublado, lluvioso, nevado) ¿Podrías describir que estrategia seguirías para desarrollar un modelo predictivo utilizando este conjunto de datos? (solo menciona pasos y técnicas) (2pts)

Para desarrollar un modelo predictivo que estime el consumo de combustible de los autobuses en Barcelona, seguiríamos los siguientes pasos:

En primer lugar, cargaríamos y exploraríamos el conjunto de datos. Esto incluiría la importación de los datos, la detección y manejo de valores nulos y la transformación de las variables categóricas a un formato adecuado para el análisis, como factores o variables dummy. Además, realizaríamos una exploración estadística y visual para identificar distribuciones, posibles valores atípicos y patrones relevantes en los datos. En caso de que las variables continuas presenten escalas muy diferentes, consideraríamos normalizarlas o estandarizarlas.

El siguiente paso sería la selección de variables. Para ello, comenzaríamos con un análisis de correlaciones para identificar relaciones entre las variables y detectar posibles problemas de multicolinealidad. Además, utilizaríamos técnicas como el análisis de componentes principales (PCA) para reducir la dimensionalidad si fuera necesario. También aplicaríamos pruebas estadísticas como ANOVA y el análisis de información mutua para determinar la relevancia de las variables en la predicción del consumo de combustible. A partir de estos análisis, seleccionaríamos las variables más significativas para el modelo.

Una vez definidas las variables, procederíamos a construir el modelo predictivo. Para ello, dividiríamos el conjunto de datos en entrenamiento y prueba, utilizando una proporción del 80% para el entrenamiento y el resto para la evaluación. Empezaríamos con un modelo de regresión

lineal múltiple, si observamos colinealidad en las variables, optaríamos por modelos de regularización como Ridge o Lasso, que penalizan los coeficientes para evitar sobreajuste. Durante el entrenamiento, aplicaríamos validación cruzada para mejorar la generalización del modelo.

Posteriormente, evaluaríamos el rendimiento del modelo mediante métricas como el coeficiente de determinación (R^2), el error cuadrático medio (RMSE) y el error absoluto medio (MAE). Si el rendimiento no es óptimo, ajustaríamos los hiperparámetros utilizando técnicas como Grid Search o Bayesian Search para mejorar la precisión del modelo.

3 PARTE II

Se dispone del siguiente dataset que contiene datos cualitativos y cuantitativos de clientes de una empresa de telecomunicaciones india en la que se detallan aspectos de los clientes de la empresa. El objetivo del presente dataset es encontrar acciones concretas que nos ayuden a prevenir que un cliente haga churn:

- device_user's – device brand (Categorical)
- first_payment_amount – user's first payment amount(Numeric)
- age – user's age(Numeric or categorical?)
- city – user's city(Categorical)
- number_of_cards – #of cards user owns
- payments_initiated – #of payments initiated by user
- payments_failed – #of payments failed
- payments_completed – #of payments completed
- payments_completed_amount_first_7days – amt of payment completed in first 7 days of joining
- reward_purchase_count_first_7days – #of rewards claimed in first 7 days
- coins_redeemed_first_7days – coins redeemed in first 7 days
- is_referral – is user a referred user
- visits_feature_1 – #of visits made by user to product feature 1
- visits_feature_2 – #of visits made by user to product feature 2
- given_permission_1 – has user given permission 1
- given_permission_2 – has user given permission 2
- user_id – user identifier
- is_churned – whether user churned

Se pide: 1. Análisis exploratorio de los datos(2pts)

- análisis descriptivo de la variable objetivo (métricas+gráficos) comentando los resultados
- visualizaciones que ayuden a entender la relación entre los atributos y la variable objetivo is_churned (métricas+gráficos) comentando los resultados

2. Selección de variables, mediante el uso de técnicas estadísticas (usad al menos 2: Correlación, PCA, ANOVA, Información Mutua), para el desarrollo de un modelo de regresión logística (2p)

- justificar la elección de vuestras variables e interpretar los resultados de las técnicas usadas
- 3. Desarrollo del modelo de regresión logística (3p)
- Selección y justificación de la métrica de optimización del modelo
- Desarrollo de al menos 2 modelos y comparación de resultados (Matriz de confusión)

4. Conclusiones y vías abiertas (1p) ¿Qué recomendaciones le daríais a esta empresa para reducir churn?, ¿Cómo os ayuda el modelo que habéis calculado a llegar a estas conclusiones?

4 PARTE 2

```
[116]: # if (!require("tidyverse")) install.packages("tidyverse")
# if (!require("ggplot2")) install.packages("ggplot2")
# if (!require("cohorts")) install.packages("cohorts")
# if (!require("dplyr")) install.packages("dplyr")
# if (!require("survival")) install.packages("survival")
# if (!require("surminer")) install.packages("surminer")
# if (!require("viridis")) install.packages("viridis")
# if (!require("lubridate")) install.packages("lubridate")
# if (!require("ggcorrplot")) install.packages("ggcorrplot")
```

Updating HTML index of packages in '.Library'

Making 'packages.html' ...
done

```
[1]: library(readxl)
library(tidyverse)
library(ggplot2)
# library(cohorts)
library(dplyr)
# library(survival)
# library(surminer)
library(viridis)
library(lubridate)
library(readr)
library(gridExtra)
library(GGally)
library(tidyr)
library(ggcorrplot)
```

Attaching core tidyverse packages tidyverse
2.0.0

dplyr	1.1.4	readr	2.1.5
forcats	1.0.0	stringr	1.5.1
ggplot2	3.5.1	tibble	3.2.1
lubridate	1.9.3	tidyr	1.3.1
purrr	1.0.4		

Conflicts

```
tidyverse_conflicts()
dplyr::filter() masks stats::filter()
dplyr::lag() masks stats::lag()
```

Use the conflicted package
(<http://conflicted.r-lib.org/>) to force all conflicts to
become errors

Loading required package: viridisLite

Attaching package: 'gridExtra'

The following object is masked from 'package:dplyr':

combine

Registered S3 method overwritten by 'GGally':

method from
+.gg ggplot2

```
[2]: df = read_csv(file = 'MD004_ACFinal_customer_churn_data.csv')
```

Rows: 104143 Columns: 18

Column specification

Delimiter: ","

chr (2): device, city

dbl (15): first_payment_amount, age, number_of_cards,
payments_initiated, pa...

lgl (1): is_referral

Use `spec()` to retrieve the full column specification for this
data.

Specify the column types or set `show\_col\_types = FALSE` to quiet
this message.

```
[3]: head(df)
```

	device <chr>	first_payment_amount <dbl>	age <dbl>	city <chr>	number_of_cards <dbl>	payments_initiated <dbl>
A tibble: 6 × 18	samsung	0	20	Ahmedabad	2	1
	xiaomi	0	20	Surat	1	1
	xiaomi	0	20	Kullu	1	2
	oneplus	0	20	Mumbai	2	4
	apple	0	20	Pune	2	1
	oppo	0	20	Ahmedabad	0	1

```
[4]: str(df)
```

```
spc_tbl_ [104,143 × 18] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
 $ device                                : chr [1:104143] "samsung" "xiaomi"
"xiaomi" "oneplus" ...
 $ first_payment_amount                  : num [1:104143] 0 0 0 0 0 0 0 0 0 0 ...
 $ age                                   : num [1:104143] 20 20 20 20 20 20 20 20 20
```

```

20 20 ...
$ city : chr [1:104143] "Ahmedabad" "Surat"
"Kullu" "Mumbai" ...
$ number_of_cards : num [1:104143] 2 1 1 2 2 0 0 0 0 0 ...
$ payments_initiated : num [1:104143] 1 1 2 4 1 1 1 17 1 1
...
$ payments_failed : num [1:104143] 0 0 1 1 0 0 0 0 0 0 ...
$ payments_completed : num [1:104143] 1 1 1 2 1 1 1 12 1 1
...
$ payments_completed_amount_first_7days: num [1:104143] 0 0 0 322 0 0 0 143 0 0
...
$ reward_purchase_count_first_7days : num [1:104143] NA NA 0 2 0 0 0 6 0 NA
...
$ coins_redeemed_first_7days : num [1:104143] 0 0 0 20 0 0 0 190 0 0
...
$ is_referral : logi [1:104143] FALSE TRUE TRUE FALSE
FALSE TRUE ...
$ visits_feature_1 : num [1:104143] 3 0 0 0 0 0 1 0 0 0 ...
$ visits_feature_2 : num [1:104143] 0 0 0 0 1 0 0 0 0 0 ...
$ given_permission_1 : num [1:104143] 1 1 0 1 1 1 1 1 0 1 ...
$ given_permission_2 : num [1:104143] 0 0 1 1 1 1 0 1 0 1 ...
$ user_id : num [1:104143] 269438 139521 307352
456424 398779 ...
$ is_churned : num [1:104143] 0 0 0 0 0 0 0 0 0 0 ...
- attr(*, "spec")=
.. cols(
.. device = col_character(),
.. first_payment_amount = col_double(),
.. age = col_double(),
.. city = col_character(),
.. number_of_cards = col_double(),
.. payments_initiated = col_double(),
.. payments_failed = col_double(),
.. payments_completed = col_double(),
.. payments_completed_amount_first_7days = col_double(),
.. reward_purchase_count_first_7days = col_double(),
.. coins_redeemed_first_7days = col_double(),
.. is_referral = col_logical(),
.. visits_feature_1 = col_double(),
.. visits_feature_2 = col_double(),
.. given_permission_1 = col_double(),
.. given_permission_2 = col_double(),
.. user_id = col_double(),
.. is_churned = col_double()
.. )
- attr(*, "problems")=<externalptr>

```

El dataset se compone de 104143 registros y 18 columnas. De estas 15 son numericas, 2 characters

y 1 logical.

```
[5]: # Investigo si el dataset tiene valores nulos
colSums(is.na(df))
```

```
device 118 first\_payment\_amount 0 age 142 city 5842 number\_of\_cards 472
payments\_initiated 472 payments\_failed 472 payments\_completed 472
payments\_completed\_amount\_first\_7days 472
reward\_purchase\_count\_first\_7days 23264 coins\_redeemed\_first\_7days 472
is\_referral 0 visits\_feature\_1 2646 visits\_feature\_2 2646
given\_permission\_1 0 given\_permission\_2 0 user\_id 0 is\_churned 0
```

La mayoría de las columnas tienen valores que habra que tratar.

```
[6]: # Reemplazar valores nulos en variables categóricas con "Desconocido"
df$device[is.na(df$device)] <- "Desconocido"
df$city[is.na(df$city)] <- "Desconocido"

# Lista de columnas numéricas a imputar con la mediana
cols_mediana <- c("age", "number_of_cards", "payments_initiated",
  ↪ "payments_failed",
  ↪ "payments_completed", "payments_completed_amount_first_7days",
  ↪ "reward_purchase_count_first_7days",
  ↪ "coins_redeemed_first_7days",
  ↪ "visits_feature_1", "visits_feature_2")

# Reemplazar nulos con la mediana de cada columna
for (col in cols_mediana) {
  df[[col]][is.na(df[[col]])] <- median(df[[col]], na.rm = TRUE)
}
```

```
[7]: colSums(is.na(df))
```

```
device 0 first\_payment\_amount 0 age 0 city 0 number\_of\_cards 0
payments\_initiated 0 payments\_failed 0 payments\_completed 0
payments\_completed\_amount\_first\_7days 0
reward\_purchase\_count\_first\_7days 0 coins\_redeemed\_first\_7days 0
is\_referral 0 visits\_feature\_1 0 visits\_feature\_2 0 given\_permission\_1 0
given\_permission\_2 0 user\_id 0 is\_churned 0
```

Se eliminaron todos los nulos.

```
[8]: # Contar duplicados columna id
num_duplicated <- sum(duplicated(df$user_id))
print(num_duplicated)
```

```
[1] 0
```

No hay id's duplicados por lo que puede eliminarse la columna

```
[9]: # Eliminar columna user_id
df <- df[, !names(df) %in% c("user_id")]
```

```
[16]: # Convertir variables categoricas y binarias a factores
df$device <- as.factor(df$device)
df$city <- as.factor(df$city)
df$given_permission_1 <- as.factor(df$given_permission_1)
df$given_permission_2 <- as.factor(df$given_permission_2)
df$is_referral <- as.factor(df$is_referral)
df$is_churned <- as.factor(df$is_churned)

str(df)
```

```
tibble [104,143 × 17] (S3: tbl_df/tbl/data.frame)
 $ device                : Factor w/ 77 levels "10or","acer",...
56 71 71 52 3 53 56 71 52 56 ...
 $ first_payment_amount   : num [1:104143] 0 0 0 0 0 0 0 0 0 0 ...
 $ age                   : num [1:104143] 20 20 20 20 20 20 20 20 20
20 20 ...
 $ city                   : Factor w/ 752 levels "24 Paraganas
North",...: 10 670 384 457 556 10 670 737 327 277 ...
 $ number_of_cards        : num [1:104143] 2 1 1 2 2 0 0 0 0 0 ...
 $ payments_initiated     : num [1:104143] 1 1 2 4 1 1 1 17 1 1
...
 $ payments_failed        : num [1:104143] 0 0 1 1 0 0 0 0 0 0 ...
 $ payments_completed     : num [1:104143] 1 1 1 2 1 1 1 12 1 1
...
 $ payments_completed_amount_first_7days: num [1:104143] 0 0 0 322 0 0 0 143 0 0
...
 $ reward_purchase_count_first_7days    : num [1:104143] 1 1 0 2 0 0 0 6 0 1 ...
 $ coins_redeemed_first_7days           : num [1:104143] 0 0 0 20 0 0 0 190 0 0
...
 $ is_referral                       : Factor w/ 2 levels "FALSE","TRUE": 1 2
2 1 1 2 2 1 2 2 ...
 $ visits_feature_1                  : num [1:104143] 3 0 0 0 0 0 1 0 0 0 ...
 $ visits_feature_2                  : num [1:104143] 0 0 0 0 1 0 0 0 0 0 ...
 $ given_permission_1                : Factor w/ 2 levels "0","1": 2 2 1 2 2
2 2 2 1 2 ...
 $ given_permission_2                : Factor w/ 2 levels "0","1": 1 1 2 2 2
2 1 2 1 2 ...
 $ is_churned                        : Factor w/ 2 levels "0","1": 1 1 1 1 1
1 1 1 1 1 ...
```


5 Análisis exploratorio de los datos

5.1 VARIABLE OBJETIVO

```
[11]: # Cargar librerías necesarias
library(ggplot2)
library(dplyr)

# Calcular proporción de churn
churn_counts <- df %>%
  count(is_churned) %>%
  mutate(percentage = n / sum(n) * 100) # Convertir en porcentaje

# Visualización con etiquetas dentro de las barras
ggplot(churn_counts, aes(x = factor(is_churned), y = percentage, fill =
  ↪factor(is_churned))) +
  geom_bar(stat = "identity") +
  geom_text(aes(label = paste0(round(percentage, 1), "%"),
    vjust = 1.5, # Colocar texto dentro de la barra
    color = "white", # Hacer texto visible
    size = 6, # Ajustar tamaño del texto
    fontface = "bold") + # Hacer el texto más legible
  scale_fill_manual(values = c("#0072B2", "#D55E00")) +
  labs(title = "Distribución de la variable objetivo (is_churned)", x =
  ↪"Churn", y = "Porcentaje") +
  theme_minimal()
```

La variable objetivo `is_churned` está claramente desbalanceada, con un 71% de usuarios que no han hecho churn y solo un 28% que sí lo han realizado.

5.1.1 2.1 Variables numéricas

```
[12]: # juntar en un dataframe todas las variables numericas que se analizaran.  
data_ais_num = df %>% select_if(is.numeric)  
head(data_ais_num)
```

	first_payment_amount <dbl>	age <dbl>	number_of_cards <dbl>	payments_initiated <dbl>	payments_failed <dbl>
A tibble: 6 × 11	0	20	2	1	0
	0	20	1	1	0
	0	20	1	2	1
	0	20	2	4	1
	0	20	2	1	0
	0	20	0	1	0

```
[13]: summary(data_ais_num)
```

```

first_payment_amount      age      number_of_cards  payments_initiated
Min.   : 0.00      Min.   :20.00  Min.   : 0.000  Min.   : 1.000
1st Qu.: 2.00      1st Qu.:27.00  1st Qu.: 1.000  1st Qu.: 1.000
Median : 12.00     Median :31.00  Median : 1.000  Median : 2.000
Mean   : 34.77     Mean   :32.69  Mean   : 1.985  Mean   : 2.844
3rd Qu.: 37.00     3rd Qu.:36.00  3rd Qu.: 3.000  3rd Qu.: 3.000
Max.   :4370.00    Max.   :80.00  Max.   :30.000  Max.   :359.000

payments_failed  payments_completed  payments_completed_amount_first_7days
Min.   : 0.0000  Min.   : 1.000  Min.   : 0.00
1st Qu.: 0.0000  1st Qu.: 1.000  1st Qu.: 3.00
Median : 0.0000  Median : 1.000  Median : 21.00
Mean   : 0.4379  Mean   : 1.827  Mean   : 55.81
3rd Qu.: 0.0000  3rd Qu.: 2.000  3rd Qu.: 63.00
Max.   :30.0000  Max.   :337.000  Max.   :11107.00

reward_purchase_count_first_7days  coins_redeemed_first_7days  visits_feature_1
Min.   : 0.000  Min.   : 0.00  Min.   : 0.0000
1st Qu.: 1.000  1st Qu.: 0.00  1st Qu.: 0.0000
Median : 1.000  Median : 3.00  Median : 0.0000
Mean   : 1.809  Mean   : 22.41  Mean   : 0.2336
3rd Qu.: 2.000  3rd Qu.: 20.00  3rd Qu.: 0.0000
Max.   :304.000  Max.   :8857.00  Max.   :17.0000

visits_feature_2
Min.   : 0.0000
1st Qu.: 0.0000
Median : 0.0000
Mean   : 0.1236
3rd Qu.: 0.0000
Max.   :23.0000

```

```

[43]: # Convertir data_ais_num a formato largo
data_long <- data_ais_num %>%
  pivot_longer(cols = everything(), names_to = "variable", values_to = "value")

# Verificar que la columna 'variable' existe en data_long
if (!"variable" %in% colnames(data_long)) {
  stop("La columna 'variable' no está en data_long. Verifica la transformación_
  ↪a formato largo.")
}

```

```

}

# Obtener los nombres de las variables en data_long
var_data <- unique(data_long$variable)

# Crear una lista vacía para almacenar los gráficos de boxplot
box_plots <- list()

# Bucle para generar un boxplot por cada variable numérica en el conjunto de
  ↪ datos
for (variable in var_data) {

  # Filtrar los datos para la variable actual
  data_filtered <- data_long[data_long$variable == variable, ]

  # Verificar si hay datos suficientes para graficar
  if (nrow(data_filtered) > 0) {

    # Crear el boxplot usando ggplot2
    box_plot <- ggplot(data_filtered, aes(x = "", y = value)) +
      geom_boxplot(
        fill = "blue",          # Color de relleno
        color = "#3C0023",      # Color del borde
        na.rm = TRUE            # Ignorar valores NA
      ) +
      coord_flip() +           # Girar el boxplot horizontalmente
      labs(
        title = paste("Boxplot", variable),
        y = variable
      ) +
      theme_minimal() +
      theme(
        text = element_text(size = 12),
        panel.background = element_rect(fill = "lightgray"),
        panel.grid.major = element_line(color = "white"),
        panel.grid.minor = element_line(color = "white")
      )

    # Agregar el gráfico a la lista con el nombre de la variable como clave
    box_plots[[variable]] <- box_plot
  }
}

# Configurar el tamaño de los gráficos para la representación final
options(
  repr.plot.width = 20,
  repr.plot.height = 10


```

```

)

# Mostrar los boxplots en una cuadrícula con 4 columnas si la lista no está
  ↳ vacía
if (length(box_plots) > 0) {
  grid.arrange(
    grobs = box_plots,
    ncol = min(4, length(box_plots)) # Ajuste dinámico del número de columnas
  )
}

```



Se observa que la mayoría de las variables presentan una distribución altamente sesgada a la derecha, con una gran cantidad de valores bajos y una cola larga de valores extremos. Además, se identifican numerosos outliers, lo que dificulta la interpretación de los datos y puede afectar negativamente la estabilidad y precisión de la regresión logística, generando fallos en las predicciones. Destaca como la edad de la muestra se concentre en el rango de 28 a 35 años de edad.

```

[56]: # Cargar la librería necesaria
library(nortest)

# Aplicar el test de Anderson-Darling a cada variable en data_ais_num
for (variable in colnames(data_ais_num)) {
  cat("\n--- Test Anderson-Darling para", variable, "---\n")

  # Verificar si la variable es numérica
  if (is.numeric(data_ais_num[[variable]])) {

    # Aplicar el test de Anderson-Darling

```

```
ad_result <- ad.test(data_ais_num[[variable]])  
  
print(ad_result)  
  
}  
}
```

--- Test Anderson-Darling para first_payment_amount ---

Anderson-Darling normality test

data: data_ais_num[[variable]]
A = 14816, p-value < 2.2e-16

--- Test Anderson-Darling para age ---

Anderson-Darling normality test

data: data_ais_num[[variable]]
A = 3420.7, p-value < 2.2e-16

--- Test Anderson-Darling para number_of_cards ---

Anderson-Darling normality test

data: data_ais_num[[variable]]
A = 5121.2, p-value < 2.2e-16

--- Test Anderson-Darling para payments_initiated ---

Anderson-Darling normality test

data: data_ais_num[[variable]]
A = 14800, p-value < 2.2e-16

--- Test Anderson-Darling para payments_failed ---

Anderson-Darling normality test

data: data_ais_num[[variable]]
A = 19932, p-value < 2.2e-16

--- Test Anderson-Darling para payments_completed ---

Anderson-Darling normality test

data: data_ais_num[[variable]]
A = 22876, p-value < 2.2e-16

--- Test Anderson-Darling para payments_completed_amount_first_7days ---

Anderson-Darling normality test

data: data_ais_num[[variable]]
A = 15521, p-value < 2.2e-16

--- Test Anderson-Darling para reward_purchase_count_first_7days ---

Anderson-Darling normality test

data: data_ais_num[[variable]]
A = 13507, p-value < 2.2e-16

--- Test Anderson-Darling para coins_redeemed_first_7days ---

Anderson-Darling normality test

data: data_ais_num[[variable]]
A = 18790, p-value < 2.2e-16

--- Test Anderson-Darling para visits_feature_1 ---

Anderson-Darling normality test

data: data_ais_num[[variable]]
A = 24453, p-value < 2.2e-16

--- Test Anderson-Darling para visits_feature_2 ---

Anderson-Darling normality test

data: data_ais_num[[variable]]
A = 31058, p-value < 2.2e-16

--- Test Anderson-Darling para is_churned ---

Anderson-Darling normality test

```
data: data_ais_num[[variable]]
A = 23278, p-value < 2.2e-16
```

Dado que todas las variables numéricas tienen un p-valor < 0.05 en el test de Anderson-Darling, podemos concluir que ninguna de ellas sigue una distribución normal.

5.1.2 2.1 Variables categóricas

```
[12]: # Contar el número de categorías en variables categóricas
categorical_vars <- c("device", "city", "is_referral", "given_permission_1",
  ↪ "given_permission_2")

cat_summary <- df %>%
  select(all_of(categorical_vars)) %>%
  summarise(across(everything(), ~n_distinct(.)))

print(cat_summary)
```

```
# A tibble: 1 × 5
  device city is_referral given_permission_1 given_permission_2
  <int> <int>
<int>          <int>
<int>
1      77    752          2              2              2
```

Destaca la gran cantidad de categorías de device con 77, y city con 752 categorías. El resto son binarias.

```
[20]: round(prop.table(table(df$is_referral))*100, digits = 1)
```

```
FALSE  TRUE
58.6   41.4
```

La mayoría de los usuarios(58%) no son referenciados y los referenciados representan el 42%, siendo una variable bastante equilibrada entre sus categorías.

```
[21]: round(prop.table(table(df$given_permission_1))*100, digits = 1)
```

```
0    1
14.8 85.2
```

```
[22]: round(prop.table(table(df$given_permission_2))*100, digits = 1)
```

```
0      1
27.7 72.3
```

La mayoría de los usuarios (85%) aceptan el permiso 1, mientras que, de manera similar, el permiso 2 es aceptado por el 72% de los usuarios.

```
[23]: # Convertir correctamente is_churned de factor a numérico sin alterar valores
df$is_churned <- as.numeric(as.character(df$is_churned))

[24]: # Cargar librerías necesarias
library(ggplot2)
library(dplyr)
library(scales)

# Ajustar tamaño de los gráficos
options(repr.plot.width = 5, repr.plot.height = 4)

# Variables categóricas de interés
categorical_vars <- c("is_referral", "given_permission_1", "given_permission_2")

# Crear gráficos de barras para churn por variable categórica con mejor
↳visibilidad de etiquetas
for (var in categorical_vars) {
  churn_data <- df %>%
    group_by(.data[[var]]) %>%
    summarise(churn_rate = mean(is_churned) * 100) # Convertir a porcentaje

  p <- ggplot(churn_data, aes(x = factor(.data[[var]]), y = churn_rate, fill =
↳factor(.data[[var]]))) +
    geom_bar(stat = "identity") +
    geom_text(aes(label = paste0(round(churn_rate, 1), "%"),
      vjust = -0.3, size = 4, fontface = "bold")) + # Ajustar etiquetas
↳para mejor visibilidad
    scale_y_continuous(labels = percent_format(scale = 1), limits = c(0,
↳max(churn_data$churn_rate) + 5)) + # Espacio extra arriba
    labs(title = paste("Proporción de churn por", var), x = var, y = "Tasa de
↳churn (%)") +
    theme_minimal() +
    theme(legend.position = "none") # Ocultar leyenda si no es necesaria

  print(p)
}
```

Attaching package: 'scales'

The following object is masked from 'package:viridis':


viridis_pal

The following object is masked from 'package:purrr':


discard

The following object is masked from 'package:readr':


col_factor



Proporción de churn por given_permission_1



Proporción de churn por given_permission_2





Se aprecia que los usuarios que no accedieron al permiso 1 o 2 obtienen una mayor tasa de abandono que aquellos que las aceptaron. Por otro lado los usuarios referidos tienen un porcentaje mayor de churn tambien.

```
[15]: # Variables numéricas a analizar
numeric_vars <- c("first_payment_amount", "age", "payments_initiated",
  ↪ "payments_failed",
  ↪ "payments_completed", "payments_completed_amount_first_7days",
  ↪ "reward_purchase_count_first_7days",
  ↪ "coins_redeemed_first_7days",
  ↪ "visits_feature_1", "visits_feature_2")


# Crear boxplots de variables numéricas según churn
for (var in numeric_vars) {
  p <- ggplot(df, aes(x = factor(is_churned), y = .data[[var]], fill =
  ↪ factor(is_churned))) +
    geom_boxplot() +
    scale_fill_manual(values = c("#0072B2", "#D55E00")) +
    labs(title = paste("Distribución de", var, "según churn"), x = "Churn", y =
  ↪ var) +
    theme_minimal()

  print(p)
}
```







Distribución de payments_initiated según churn




Distribución de payments_failed según churn




Distribución de payments_completed según churn




Distribución de payments_completed_amount_first_7days







Distribución de coins_redeemed_first_7days según churn



Distribución de visits_feature_1 según churn





La única variable numérica en la que se aprecia una diferencia, aunque mínima, es age, donde se observa que los usuarios que hicieron churn tienden a tener una edad ligeramente mayor en comparación con aquellos que permanecieron en la plataforma.

5.1.3 ANÁLISIS DE CORRELACIÓN

```
[20]: #Covarianza
round(cov(data_ais_num), 3)
```

A matrix: 11 × 11 of type dbl

	first_payment_amount	age	number_of_cards
first_payment_amount	5355.463	31.898	8.047
age	31.898	61.100	2.031
number_of_cards	8.047	2.031	3.638
payments_initiated	-8.638	0.628	0.288
payments_failed	1.236	0.288	0.372
payments_completed	-9.847	0.372	0.013
payments_completed_amount_first_7days	6103.877	71.441	31.898
reward_purchase_count_first_7days	21.632	0.606	0.013
coins_redeemed_first_7days	1649.655	21.683	16.632
visits_feature_1	0.763	-0.284	-0.284
visits_feature_2	0.203	0.013	0.013


```
[21]: # Crear la matriz de correlación usando Spearman
spearman_correlation <- cor(data_ais_num, method = "spearman", use = "complete.
↪obs")
#Correlación
round(spearman_correlation, 3)
```

A matrix: 11 × 11 of type dbl

	first_payment_amount	age	nu
first_payment_amount	1.000	0.042	0.
age	0.042	1.000	0.
number_of_cards	0.128	0.222	1.
payments_initiated	0.035	0.028	0.
payments_failed	0.050	0.028	0.
payments_completed	-0.031	0.051	0.
payments_completed_amount_first_7days	0.747	0.083	0.
reward_purchase_count_first_7days	0.315	0.048	0.
coins_redeemed_first_7days	0.472	0.035	0.
visits_feature_1	0.043	-0.068	-0.
visits_feature_2	0.016	0.008	0.

```
[22]: # Ajustar tamaño del gráfico
options(repr.plot.width = 7, repr.plot.height = 7)

# Graficar la matriz de correlación con Spearman
corrplot::corrplot(spearman_correlation,
  type = "upper",
  number.cex = .6,
  tl.col = "black",
  tl.srt = 90)
```



Se aprecia que hay pocas correlaciones fuertes entre las variables, destacando las correlaciones entre pagos iniciados y completados, entre pagos completados y recompensas por compras. Todas estas relaciones son bastante obvias a priori. La variable dependiente no tiene correlación significativa con ninguna variable.

6 PCA

```
[25]: # Convertir variables binarias a numéricas (0 y 1)
df <- df %>%
  mutate(across(c(is_referral, given_permission_1, given_permission_2),
    ~ as.numeric(.) - 1))

# Verificar la transformación
```

```
str(df)
```

```
tibble [104,143 × 17] (S3: tbl_df/tbl/data.frame)
 $ device                                     : Factor w/ 77 levels "10or","acer",...:
56 71 71 52 3 53 56 71 52 56 ...
 $ first_payment_amount                     : num [1:104143] 0 0 0 0 0 0 0 0 0 0 ...
 $ age                                      : num [1:104143] 20 20 20 20 20 20 20 20 20
20 20 ...
 $ city                                     : Factor w/ 752 levels "24 Paraganas
North",...: 10 670 384 457 556 10 670 737 327 277 ...
 $ number_of_cards                         : num [1:104143] 2 1 1 2 2 0 0 0 0 0 ...
 $ payments_initiated                     : num [1:104143] 1 1 2 4 1 1 1 17 1 1
...
 $ payments_failed                        : num [1:104143] 0 0 1 1 0 0 0 0 0 0 ...
 $ payments_completed                    : num [1:104143] 1 1 1 2 1 1 1 12 1 1
...
 $ payments_completed_amount_first_7days: num [1:104143] 0 0 0 322 0 0 0 143 0 0
...
 $ reward_purchase_count_first_7days    : num [1:104143] 1 1 0 2 0 0 0 6 0 1 ...
 $ coins_redeemed_first_7days           : num [1:104143] 0 0 0 20 0 0 0 190 0 0
...
 $ is_referral                          : num [1:104143] 0 1 1 0 0 1 1 0 1 1 ...
 $ visits_feature_1                     : num [1:104143] 3 0 0 0 0 0 1 0 0 0 ...
 $ visits_feature_2                     : num [1:104143] 0 0 0 0 1 0 0 0 0 0 ...
 $ given_permission_1                   : num [1:104143] 1 1 0 1 1 1 1 1 0 1 ...
 $ given_permission_2                   : num [1:104143] 0 0 1 1 1 1 0 1 0 1 ...
 $ is_churned                           : num [1:104143] 0 0 0 0 0 0 0 0 0 0 ...
```

```
[26]: # Filtrar solo las variables numéricas
df_numeric <- df %>%
  select(where(is.numeric))

# Verificar la estructura del nuevo dataframe
str(df_numeric)
```

```
tibble [104,143 × 15] (S3: tbl_df/tbl/data.frame)
 $ first_payment_amount                     : num [1:104143] 0 0 0 0 0 0 0 0 0 0 ...
 $ age                                      : num [1:104143] 20 20 20 20 20 20 20 20 20
20 20 ...
 $ number_of_cards                         : num [1:104143] 2 1 1 2 2 0 0 0 0 0 ...
 $ payments_initiated                     : num [1:104143] 1 1 2 4 1 1 1 17 1 1
...
 $ payments_failed                        : num [1:104143] 0 0 1 1 0 0 0 0 0 0 ...
 $ payments_completed                    : num [1:104143] 1 1 1 2 1 1 1 12 1 1
...
 $ payments_completed_amount_first_7days: num [1:104143] 0 0 0 322 0 0 0 143 0 0
...
 $ reward_purchase_count_first_7days    : num [1:104143] 1 1 0 2 0 0 0 6 0 1 ...
```

```

$ coins_redeemed_first_7days      : num [1:104143] 0 0 0 20 0 0 0 190 0 0
...
$ is_referral                     : num [1:104143] 0 1 1 0 0 1 1 0 1 1 ...
$ visits_feature_1                 : num [1:104143] 3 0 0 0 0 0 1 0 0 0 ...
$ visits_feature_2                 : num [1:104143] 0 0 0 0 1 0 0 0 0 0 ...
$ given_permission_1               : num [1:104143] 1 1 0 1 1 1 1 1 0 1 ...
$ given_permission_2               : num [1:104143] 0 0 1 1 1 1 0 1 0 1 ...
$ is_churned                       : num [1:104143] 0 0 0 0 0 0 0 0 0 0 ...

```

```

[28]: pca = df_numeric

# Aplicar PCA con estandarización
pca <- prcomp(pca, scale = TRUE)

# Mostrar resumen del PCA
summary(pca)

```

Importance of components:

	PC1	PC2	PC3	PC4	PC5	PC6	PC7
Standard deviation	1.8213	1.3652	1.19333	1.07651	1.04348	1.00114	0.96298
Proportion of Variance	0.2211	0.1242	0.09494	0.07726	0.07259	0.06682	0.06182
Cumulative Proportion	0.2211	0.3454	0.44032	0.51758	0.59017	0.65699	0.71881

	PC8	PC9	PC10	PC11	PC12	PC13	PC14
Standard deviation	0.9312	0.89487	0.8798	0.85666	0.7569	0.52291	0.37650
Proportion of Variance	0.0578	0.05339	0.0516	0.04892	0.0382	0.01823	0.00945
Cumulative Proportion	0.7766	0.83000	0.8816	0.93053	0.9687	0.98695	0.99640

	PC15
Standard deviation	0.2323
Proportion of Variance	0.0036
Cumulative Proportion	1.0000

```

[29]: # Gráfico de la varianza explicada
explained_var = pca$sdev^2 / sum(pca$sdev^2) * 100


explained_var_df <- data.frame(
  PC = paste0("PC", 1:length(explained_var)),
  Variance = explained_var
)

options(repr.plot.width = 10,
  repr.plot.height = 10)

# Crear un gráfico de barras para la varianza explicada
ggplot(explained_var_df, aes(x = reorder(PC, -Variance), y = Variance)) +
  geom_bar(stat = "identity", fill = "#990000", color = "#990000") +
  geom_text(aes(label = round(Variance, 1)), vjust = -0.5, size = 5) +
  labs(
    title = "Porcentaje de Varianza Explicada por Componente Principal",

```

```
x = "Componentes Principales",
y = "Porcentaje de Varianza Explicada"
) +
theme_minimal(base_size = 14)
```



Se decide optar por el uso de 8 factores que representan el 81% de la varianza.

```
[34]: # Mostrar las cargas de los primeros ocho componentes principales
cargas <- as.data.frame(round(pca$rotation[, 1:8], 3))
print(cargas)
```

	PC1	PC2	PC3	PC4	PC5	PC6
first_payment_amount	0.160	0.559	-0.090	-0.090	0.073	-0.039
age	0.038	0.074	-0.184	0.335	-0.659	-0.190

number_of_cards	0.130	0.113	0.064	0.437	-0.432	0.207
payments_initiated	0.461	-0.333	-0.007	0.017	0.013	0.023
payments_failed	0.255	-0.169	0.073	0.064	-0.090	0.040
payments_completed	0.447	-0.325	-0.060	0.005	0.054	0.010
payments_completed_amount_first_7days	0.318	0.499	-0.120	-0.078	0.042	-0.064
reward_purchase_count_first_7days	0.475	-0.149	-0.081	-0.036	0.079	-0.058
coins_redeemed_first_7days	0.353	0.344	-0.101	-0.090	0.062	-0.090
is_referral	-0.046	-0.117	-0.278	-0.107	0.026	-0.654
visits_feature_1	0.061	0.009	0.400	-0.518	-0.268	-0.044
visits_feature_2	0.065	0.011	0.439	-0.362	-0.402	-0.150
given_permission_1	0.041	0.051	0.395	0.395	0.127	-0.427
given_permission_2	0.030	0.059	0.460	0.281	0.273	-0.314
is_churned	-0.121	-0.123	-0.341	-0.149	-0.163	-0.411
	PC7	PC8				
first_payment_amount	-0.153	0.106				
age	-0.143	-0.045				
number_of_cards	0.404	0.069				
payments_initiated	-0.101	0.059				
payments_failed	-0.602	0.592				
payments_completed	0.129	-0.180				
payments_completed_amount_first_7days	-0.073	0.043				
reward_purchase_count_first_7days	0.176	-0.238				
coins_redeemed_first_7days	0.084	-0.125				
is_referral	0.432	0.523				
visits_feature_1	0.124	0.061				
visits_feature_2	-0.008	-0.091				
given_permission_1	-0.058	-0.167				
given_permission_2	-0.078	-0.026				
is_churned	-0.387	-0.456				

```
[35]: # Identificar las variables con mayor peso absoluto en cada componente principal
df_subset <- cargas %>%
  mutate(Variable = rownames(.)) %>% # Agregar nombres de variables como
  ↪columna
  pivot_longer(cols = starts_with("PC"), names_to = "PC", values_to = "Carga")
  ↪%>%
  group_by(PC) %>%
  slice_max(abs(Carga), n = 1) %>% # Seleccionar la de mayor valor absoluto
  ungroup() %>%
  select(PC, Variable, Carga)

print(df_subset)
```

```
# A tibble: 8 × 3
  PC      Variable      Carga
<chr> <chr>
<dbl>
1 PC1    reward_purchase_count_first_7days 0.475
```

```

2 PC2    first_payment_amount          0.559
3 PC3    given_permission_2            0.46
4 PC4    visits_feature_1
-0.518
5 PC5    age
-0.659
6 PC6    is_referral
-0.654
7 PC7    payments_failed
-0.602
8 PC8    payments_failed              0.592

```

```

[36]: # Filtrar el dataframe original para mantener solo las variables seleccionadas
df_final <- df %>%
  select(is_churned, reward_purchase_count_first_7days, first_payment_amount,
         visits_feature_2, given_permission_1, age, is_referral,
         payments_failed, number_of_cards)

# Verificar la estructura del dataframe final
str(df_final)

# Mostrar las primeras filas para revisar la integración
head(df_final)

```

```

tibble [104,143 × 9] (S3: tbl_df/tbl/data.frame)
 $ is_churned                : Factor w/ 2 levels "0","1": 1 1 1 1 1 1 1
1 1 1 ...
 $ reward_purchase_count_first_7days: num [1:104143] 1 1 0 2 0 0 0 6 0 1 ...
 $ first_payment_amount           : num [1:104143] 0 0 0 0 0 0 0 0 0 0 ...
 $ visits_feature_2               : num [1:104143] 0 0 0 0 1 0 0 0 0 0 ...
 $ given_permission_1             : num [1:104143] 1 1 0 1 1 1 1 1 0 1 ...
 $ age                           : num [1:104143] 20 20 20 20 20 20 20 20 20
20 ...
 $ is_referral                   : num [1:104143] 0 1 1 0 0 1 1 0 1 1 ...
 $ payments_failed               : num [1:104143] 0 0 1 1 0 0 0 0 0 0 ...
 $ number_of_cards               : num [1:104143] 2 1 1 2 2 0 0 0 0 0 ...

```

	is_churned <fct>	reward_purchase_count_first_7days <dbl>	first_payment_amount <dbl>	visits_feature_2 <dbl>
	0	1	0	0
	0	1	0	0
A tibble: 6 × 9	0	0	0	0
	0	2	0	0
	0	0	0	1
	0	0	0	0

```

[37]: # Seleccionar todas las columnas excepto is_churned
df_cor <- df_final %>% select(-is_churned)

```




```

# Calcular la matriz de correlación de Spearman
cor_matrix <- cor(df_cor, method = "spearman", use = "complete.obs")

# Visualizar la matriz de correlación
ggcorrplot(cor_matrix,
  type = "lower", # Mostrar solo la mitad inferior
  lab = TRUE,     # Mostrar los valores numéricos
  colors = c("red", "white", "blue"), # Colores de la escala
  title = "Matriz de Correlación (Spearman)",
  outline.color = "black")

```



```
[ ]: Entre las variables seleccionadas a partir del análisis de componentes  
↳ principales (PCA), se ha comprobado que no existe colinealidad.
```

7 ENTROPIA

```
[33]: library(FSelectorRcpp)
library(ggplot2)
library(patchwork) # Necesario para wrap_plots()
library(purrr) # Necesario para pmap()

# Convertir is_churned a factor para evitar warnings
df$is_churned <- factor(df$is_churned, levels = c(0,1))

# Generar una paleta de colores en la misma tonalidad (rojo)
colores <- scales::seq_gradient_pal("#ffcccc", "#990000", "Lab")(seq(0, 1,
↳ length.out = 3))


# Función para calcular y graficar la importancia de atributos
graficar_importancia <- function(data, formula, type, titulo, color) {
  ig <- information_gain(formula = formula, data = data, type = type)

  ggplot(ig, aes(x = reorder(attributes, importance), y = importance)) +
    geom_bar(stat = "identity", fill = color, color = color) +
    geom_text(aes(label = round(importance, 3)), color = "black", size = 5,
↳ hjust = -0.2) +
    coord_flip() +
    labs(
      title = titulo,
      x = "Atributos",
      y = "Importancia"
    ) +
    theme_minimal(base_size = 14) +
    theme(axis.text.y = element_text(size = 12))
}

# Generar gráficos para los tres tipos de métricas
tipos <- c("infogain", "gainratio", "symuncert")
titulos <- c("Importancia de Atributos (Information Gain)",
  "Importancia de Atributos (Gain Ratio)",
  "Importancia de Atributos (Symmetrical Uncertainty)")

# Usar purrr::pmap para pasar los colores a la función
graficos <- pmap(
  list(tipos, titulos, colores),
  ~ graficar_importancia(df, is_churned ~ ., ..1, ..2, ..3)
)
```

```
# Mostrar los gráficos en un layout usando patchwork
wrap_plots(graficos, ncol = 1)
```



El análisis de Information Gain Analysis (IGA) nos permite identificar las variables más relevantes para predecir el churn en los clientes. En este caso, los resultados muestran que las variables relacionadas con las transacciones y el uso de recompensas tienen el mayor impacto en la predicción.

Las tres métricas analizadas (Information Gain, Gain Ratio y Symmetrical Uncertainty) coinciden en destacar como más importantes las siguientes variables:

payments_completed_amount_first_7days, reward_purchase_count_first_7days, first_payment_amount, payments_completed, coins_redeemed_first_7days. Esto sugiere que el comportamiento de pago y el uso de recompensas dentro de los primeros días de actividad

del cliente son factores clave para determinar si hará churn o no.

Por otro lado, variables como `visits_feature_2`, `payments_failed`, `device` y `age` aparecen con una importancia muy baja en todas las métricas, lo que indica que tienen poca influencia en la predicción y podrían descartarse para optimizar el modelo.

8 Desarrollo del modelo de regresión logística

8.1 MODELO 1(Basado en PCA)

```
[38]: # Selección variables modelo basado en pca
df_subset = df_final
# Convertir variable objetivo en factor
df_subset$is_churned = factor(df_subset$is_churned, levels = c('0', '1'))
```

```
[39]: # Cargar el paquete
library(rsample)
set.seed(50)

# Partición de los datos en entrenamiento y prueba
split = initial_split(df_subset, prop = 0.8, strata = is_churned)
df_train = training(split)
df_test = testing(split)

# Definir las variables objetivo
ytrain = df_train$is_churned
ytest = df_test$is_churned
```

8.2 TRAIN

```
[40]: # Verificar si is_churned está correctamente definido
df_train$is_churned <- factor(df_train$is_churned, levels = c(0,1))

# Ajustar la regresión logística usando todas las variables excepto is_churned
mrl1 <- glm(is_churned ~ ., data = df_train, family = "binomial")

# Mostrar resultados
summary(mrl1)
```

Warning message:

"glm.fit: fitted probabilities numerically 0 or 1 occurred"

Call:

```
glm(formula = is_churned ~ ., family = "binomial", data = df_train)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.8409935	0.0386119	-21.781	< 2e-16 ***

```

reward_purchase_count_first_7days -0.1282534  0.0051373 -24.965 < 2e-16 ***
first_payment_amount               -0.0050483  0.0001921 -26.273 < 2e-16 ***
visits_feature_2                   -0.2294787  0.0218483 -10.503 < 2e-16 ***
given_permission_1                 -0.3767276  0.0211562 -17.807 < 2e-16 ***
age                                0.0222049  0.0009782  22.699 < 2e-16 ***
is_referral                        0.3952076  0.0159661  24.753 < 2e-16 ***
payments_failed                   -0.0668720  0.0088240  -7.578 3.5e-14 ***
number_of_cards                   -0.1379904  0.0049755 -27.734 < 2e-16 ***
---

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

```

Null deviance: 99855  on 83313  degrees of freedom
Residual deviance: 94390  on 83305  degrees of freedom
AIC: 94408

```

Number of Fisher Scoring iterations: 5

```

[41]: # Cargar el paquete
library(caret)

# Predicciones de probabilidades
mrl1_prob <- predict(mrl1, df_train, type = "response")

# Predicción binaria
mrl1_pred <- ifelse(mrl1_prob > 0.5, 1, 0)
# Matriz de confusión
confusionMatrix(as.factor(mrl1_pred), as.factor(ytrain))

```

Loading required package: lattice

Attaching package: 'caret'

The following object is masked from 'package:purrr':

lift

Confusion Matrix and Statistics

```

      Reference
Prediction  0    1
0  58484 22042
1   935  1853

```

```

Accuracy : 0.7242
95% CI : (0.7212, 0.7272)
No Information Rate : 0.7132
P-Value [Acc > NIR] : 8.616e-13

Kappa : 0.084

McNemar's Test P-Value : < 2.2e-16

Sensitivity : 0.98426
Specificity : 0.07755
Pos Pred Value : 0.72627
Neg Pred Value : 0.66463
Prevalence : 0.71319
Detection Rate : 0.70197
Detection Prevalence : 0.96654
Balanced Accuracy : 0.53091

'Positive' Class : 0

```

El modelo presenta un accuracy del 72.42%, pero con una especificidad muy baja (7.76%), lo que indica que tiene dificultades para detectar correctamente los casos de churn (clase 1). La sensibilidad es alta (98.43%), lo que significa que el modelo predice correctamente la mayoría de los casos de no churn (clase 0). Sin embargo, el bajo valor de especificidad sugiere que el modelo aún presenta un problema de desbalance y no logra distinguir correctamente entre clientes que hacen churn y los que no. Para mejorar, se opta por ajustar el umbral de decisión.

```

[42]: # Probar con un umbral más bajo
mrl1_pred <- ifelse(mrl1_prob > 0.3, 1, 0)

# Matriz de confusión
confusionMatrix(as.factor(mrl1_pred), as.factor(ytrain))

```

Confusion Matrix and Statistics

```

Reference
Prediction  0    1
0 37417  9219
1 22002 14676

Accuracy : 0.6253
95% CI : (0.622, 0.6285)
No Information Rate : 0.7132
P-Value [Acc > NIR] : 1

Kappa : 0.2103

```

McNemar's Test P-Value : <2e-16

Sensitivity : 0.6297
Specificity : 0.6142
Pos Pred Value : 0.8023
Neg Pred Value : 0.4001
Prevalence : 0.7132
Detection Rate : 0.4491
Detection Prevalence : 0.5598
Balanced Accuracy : 0.6220

'Positive' Class : 0

Después de aplicar un umbral de 0.3, el modelo mejora en la detección de la clase 1 (churn), logrando una sensibilidad del 62.97%, lo que indica que ahora es capaz de identificar más clientes que hacen churn en comparación con el modelo anterior. Además, la especificidad es del 61.42%, lo que significa que también ha mejorado en la identificación de clientes que no hacen churn.

El accuracy del modelo es del 62.53%, lo que muestra una ligera disminución respecto a la versión anterior, pero se ha logrado un mejor equilibrio en la detección de ambas clases. En general, ajustar el umbral ha permitido mejorar la capacidad del modelo para detectar churn, aunque su capacidad predictiva sigue siendo limitada.

```
[43]: # HACER CURVA ROC
# Instalar y cargar pROC si no lo tienes instalado
if (!require("pROC")) install.packages("pROC", dependencies=TRUE)
library(pROC)

# Calcular la curva ROC
roc_curve <- roc(ytrain, mrl1_prob)

# Plotear la curva ROC
plot(roc_curve, col="blue", lwd=2, main="Curva ROC - Modelo de Regresión
↳Logística")

# Calcular y mostrar el AUC
auc_value <- auc(roc_curve)
cat("Área bajo la curva (AUC):", auc_value, "\n")
```

Loading required package: pROC

Type 'citation("pROC")' for a citation.

Attaching package: 'pROC'


The following objects are masked from 'package:stats':

```
cov, smooth, var
```

```
Setting levels: control = 0, case = 1
```

```
Setting direction: controls < cases
```

```
Área bajo la curva (AUC): 0.6679965
```



La curva ROC evalúa el desempeño del modelo de clasificación binaria para distinguir entre clientes que hacen churn (1) y los que no (0). El AUC de 0.668 indica que el modelo tiene un rendimiento superior al azar, pero sigue siendo reducido y lejos de un clasificador óptimo (AUC cercano a 1).

8.3 TEST

```
[44]: # Verificar si is_churned está correctamente definido
df_test$is_churned <- factor(df_test$is_churned, levels = c(0,1))

# Ajustar la regresión logística usando todas las variables excepto is_churned
mrl1 <- glm(is_churned ~ ., data = df_test, family = "binomial")
summary(mrl1)
```

Call:

```
glm(formula = is_churned ~ ., family = "binomial", data = df_test)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.893187	0.076813	-11.628	< 2e-16 ***
reward_purchase_count_first_7days	-0.139129	0.010410	-13.365	< 2e-16 ***
first_payment_amount	-0.003906	0.000361	-10.821	< 2e-16 ***
visits_feature_2	-0.313306	0.045994	-6.812	9.63e-12 ***
given_permission_1	-0.348579	0.042193	-8.261	< 2e-16 ***
age	0.023998	0.001960	12.247	< 2e-16 ***
is_referral	0.358790	0.031913	11.243	< 2e-16 ***
payments_failed	-0.072205	0.018059	-3.998	6.38e-05 ***
number_of_cards	-0.147586	0.010039	-14.701	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 24964 on 20828 degrees of freedom
Residual deviance: 23640 on 20820 degrees of freedom
AIC: 23658

Number of Fisher Scoring iterations: 5

```
[45]: # Predicciones de probabilidades
mrl1_prob <- predict(mrl1, df_test, type = "response")

# Predicción binaria
mrl1_pred <- ifelse(mrl1_prob > 0.3, 1, 0)
# Matriz de confusión
confusionMatrix(as.factor(mrl1_pred), as.factor(ytest))
```

Confusion Matrix and Statistics

	Reference	
Prediction	0	1
0	9254	2323

1 5601 3651

Accuracy : 0.6196
95% CI : (0.6129, 0.6262)
No Information Rate : 0.7132
P-Value [Acc > NIR] : 1

Kappa : 0.2011

McNemar's Test P-Value : <2e-16

Sensitivity : 0.6230
Specificity : 0.6111
Pos Pred Value : 0.7993
Neg Pred Value : 0.3946
Prevalence : 0.7132
Detection Rate : 0.4443
Detection Prevalence : 0.5558
Balanced Accuracy : 0.6171

'Positive' Class : 0

El test reduce la precisión del modelo al 57%, disminuyendo la sensibilidad al 48%, lo que significa que el modelo tiene dificultades para identificar correctamente los casos de churn. Sin embargo, la especificidad aumenta al 79%, lo que indica que el modelo es más eficaz en la clasificación de los clientes que no hacen churn. Este cambio sugiere un sesgo hacia la clase 0 (no churn), lo que puede resultar problemático si el objetivo es detectar clientes propensos a abandonar.

```
[40]: # Calcular la curva ROC
roc_curve <- roc(ytest, mrl1_prob)


# Plotear la curva ROC
plot(roc_curve, col="blue", lwd=2, main="Curva ROC - Modelo de Regresión
↳Logística")

# Calcular y mostrar el AUC
auc_value <- auc(roc_curve)
cat("Área bajo la curva (AUC):", auc_value, "\n")
```

Setting levels: control = 0, case = 1

Setting direction: controls < cases

Área bajo la curva (AUC): 0.6624071



El AUC mantiene un rendimiento reducido en el test del 66%.

8.4 MODELO 2 (Basado en IGA)

8.5 TRAIN

```
[46]: df_subset = df %>% select (is_churned,payments_completed_amount_first_7days,  
reward_purchase_count_first_7days,  
first_payment_amount,  
payments_completed,  
coins_redeemed_first_7days)
```

```
[47]: library(rsample)
      set.seed(50)

      # Partición de los datos en entrenamiento y prueba
      split = initial_split(df_subset, prop = 0.8, strata = is_churned)
      df_train = training(split)
      df_test = testing(split)

      # Definir las variables objetivo
      ytrain = df_train$is_churned
      ytest = df_test$is_churned
```

```
[48]: # Ajustar la regresión logística correctamente
      mrl2 <- glm(is_churned ~ payments_completed_amount_first_7days+
      reward_purchase_count_first_7days+
      first_payment_amount+
      payments_completed+
      coins_redeemed_first_7days,
              data = df_train, family = "binomial")

      summary(mrl2)
```

Warning message:

"glm.fit: fitted probabilities numerically 0 or 1 occurred"

Call:

```
glm(formula = is_churned ~ payments_completed_amount_first_7days +
      reward_purchase_count_first_7days + first_payment_amount +
      payments_completed + coins_redeemed_first_7days, family = "binomial",
      data = df_train)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.3117769	0.0156243	-19.955	< 2e-16
payments_completed_amount_first_7days	-0.0025686	0.0002640	-9.729	< 2e-16
reward_purchase_count_first_7days	0.0659902	0.0090612	7.283	3.27e-13
first_payment_amount	-0.0029390	0.0003162	-9.294	< 2e-16
payments_completed	-0.2583067	0.0105501	-24.484	< 2e-16
coins_redeemed_first_7days	-0.0062870	0.0004987	-12.607	< 2e-16

```
(Intercept) ***
payments_completed_amount_first_7days ***
reward_purchase_count_first_7days ***
first_payment_amount ***
payments_completed ***
coins_redeemed_first_7days ***
---
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 99855 on 83313 degrees of freedom
Residual deviance: 95436 on 83308 degrees of freedom
AIC: 95448

Number of Fisher Scoring iterations: 6

```
[49]: # Predicciones de probabilidades
mrl2_prob <- predict(mrl2, df_train, type = "response")

# Probar con un umbral más bajo
mrl2_pred <- ifelse(mrl2_prob > 0.3, 1, 0)

# Matriz de confusión
confusionMatrix(as.factor(mrl2_pred), as.factor(ytrain))
```

Confusion Matrix and Statistics

	Reference	
Prediction	0	1
0	29038	5034
1	30381	18861

Accuracy : 0.5749
95% CI : (0.5716, 0.5783)
No Information Rate : 0.7132
P-Value [Acc > NIR] : 1

Kappa : 0.2111

McNemar's Test P-Value : <2e-16

Sensitivity : 0.4887
Specificity : 0.7893
Pos Pred Value : 0.8523
Neg Pred Value : 0.3830
Prevalence : 0.7132
Detection Rate : 0.3485
Detection Prevalence : 0.4090
Balanced Accuracy : 0.6390

'Positive' Class : 0

El modelo identifica correctamente a los clientes que no hacen churn (especificidad del 78.93%),

pero tiene dificultades para detectar a aquellos que sí lo hacen (sensibilidad del 48.87%). Como resultado la precisión del modelo se reduce al 57%.

```
[50]: # Calcular la curva ROC
roc_curve <- roc(ytrain, mrl2_prob)


# Plotear la curva ROC
plot(roc_curve, col="blue", lwd=2, main="Curva ROC - Modelo de Regresión
↳Logística")

# Calcular y mostrar el AUC
auc_value <- auc(roc_curve)
cat("Área bajo la curva (AUC):", auc_value, "\n")
```

Setting levels: control = 0, case = 1

Setting direction: controls < cases

Área bajo la curva (AUC): 0.7380944



El AUC de 0.738 indica una mejora en la capacidad del modelo para diferenciar entre clientes que hacen churn y los que no. Sin embargo, los indicadores siguen desbalanceados, como se observa en la sensibilidad del 48.87%. Esto puede deberse al desbalance de clases en los datos o a un umbral de decisión no optimizado, lo que afecta la clasificación correcta de los casos de churn.

8.6 TEST

```
[51]: # Ajustar la regresión logística correctamente
mrl2 <- glm(is_churned ~ payments_completed_amount_first_7days +
reward_purchase_count_first_7days +
first_payment_amount +
payments_completed +
coins_redeemed_first_7days,
```

```
data = df_test, family = "binomial")
```

```
summary(mrl2)
```

Call:

```
glm(formula = is_churned ~ payments_completed_amount_first_7days +  
  reward_purchase_count_first_7days + first_payment_amount +  
  payments_completed + coins_redeemed_first_7days, family = "binomial",  
  data = df_test)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-3.469e-01	3.057e-02	-11.346	< 2e-16
payments_completed_amount_first_7days	-5.909e-05	3.895e-04	-0.152	0.8794
reward_purchase_count_first_7days	4.181e-02	1.771e-02	2.360	0.0183
first_payment_amount	-3.559e-03	5.332e-04	-6.675	2.47e-11
payments_completed	-2.497e-01	2.027e-02	-12.318	< 2e-16
coins_redeemed_first_7days	-7.669e-03	9.220e-04	-8.318	< 2e-16

(Intercept)	***
payments_completed_amount_first_7days	
reward_purchase_count_first_7days	*
first_payment_amount	***
payments_completed	***
coins_redeemed_first_7days	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 24964 on 20828 degrees of freedom
Residual deviance: 24025 on 20823 degrees of freedom
AIC: 24037

Number of Fisher Scoring iterations: 5

```
[52]: # Predicciones de probabilidades  
mrl2_prob <- predict(mrl2, df_test, type = "response")  
# Probar con un umbral más bajo  
mrl2_pred <- ifelse(mrl2_prob > 0.3, 1, 0)  
  
# Matriz de confusión  
confusionMatrix(as.factor(mrl2_pred), as.factor(ytest))
```

Confusion Matrix and Statistics


```

      Reference
Prediction    0    1
      0 7151 1248
      1 7704 4726

      Accuracy : 0.5702
      95% CI : (0.5635, 0.577)
      No Information Rate : 0.7132
      P-Value [Acc > NIR] : 1

      Kappa : 0.206

      McNemar's Test P-Value : <2e-16

      Sensitivity : 0.4814
      Specificity : 0.7911
      Pos Pred Value : 0.8514
      Neg Pred Value : 0.3802
      Prevalence : 0.7132
      Detection Rate : 0.3433
      Detection Prevalence : 0.4032
      Balanced Accuracy : 0.6362

      'Positive' Class : 0

```

Los resultados en el conjunto de test son consistentes con los obtenidos en el train, lo que indica estabilidad en el modelo. Sin embargo, el desempeño sigue estando sesgado hacia la clase “no churn”, favoreciendo la correcta clasificación de estos casos a expensas de una menor capacidad para identificar a los clientes que hacen churn.

```

[53]: # Calcular la curva ROC
      roc_curve <- roc(ytest, mrl2_prob)

      # Plotear la curva ROC
      plot(roc_curve, col="blue", lwd=2, main="Curva ROC - Modelo de Regresión
      ↪Logística")


      # Calcular y mostrar el AUC
      auc_value <- auc(roc_curve)
      cat("Área bajo la curva (AUC):", auc_value, "\n")

```

Setting levels: control = 0, case = 1

Setting direction: controls < cases

Área bajo la curva (AUC): 0.737429



[]: La curva ROC mantiene un AUC moderado del 73%, consistente con el resultado ↪ obtenido en el conjunto de prueba.

9 Conclusiones y vías abiertas

En esta investigación se han analizado los factores que producían el abandono o churn de los clientes de los servicios proporcionados por una empresa de telecomunicaciones en la India. En primer lugar, se realizó un análisis general para entender las variables. Se ha observado que el dataset estaba compuesto de 104.143 observaciones y 18 variables, de las cuales 15 de ellas eran numéricas, 2 tipo carácter y 1 tipo lógico. A continuación se ha calculado la cantidad de nulos por columna y se ha visto que había varias columnas con estos. Dado que los nulos se concentraban en variables numéricas se eligió substituirlos por la mediana. Además se transformaron las variables binarias y categóricas a factor. Una vez el dataset ya está limpio y listo para trabajar, se pasó a

analizar la variable objetivo `is_churned` la cual esta claramente desbalanceada dado que el 70% es categoría no churn. A continuación se realizaron boxplots con las variables numericas restantes y asi conocer su distribución. En general las distribuciones estaban claramente sesgadas a la derecha con valores proximos al 0, hay excepciones como la edad que tenia el IQR entre los 28-35 años. Se realizo el test Anderson-Darling para conocer si cumplian con normalidad, todos los caso eran extremadamente significativos o lo que es lo mismo, distribuciones no normales.

Posteriormente se analizaron las distribuciones de algunas variables categoricas. La variable `is_referred` esta bastante equilibrada, la mayoría de los usuarios(58%) no son referenciados, pero los referenciados tienn eun 42%. Por otro lado, given permission_1 y given permission_2 la gran mayoría de los usarios dan el permiso con su 85% y 72%. Una vez se entiende la distribución de estas variables se estudian en conjunto con la variable objetivo `is_churned`. De aqui se extrae que contraintuitivamente los usuarios que vienen referenciados obtienen un porcentaje de churn mayor siendo el 34.6% respecto al 24.5% de aquellos no refernciados. En el caso de given_permission_1 aquellos que no dieron permiso tien un churn del 37.5% mientras que los que aceptan obtienen el 27.1%. Se hizo con las variables numericas y lo unica que destacaba es que la edad aumentaba ligeramente en aquellos que hacian churn.

Posteriormente para la selección de variables se realizaron análisis de correlaciones, PCA y IGA. El analisis de correlaciones mostro que ninguna variable explicativa tenia correlación significativa con la variable objetivo, pero si habian correlaciones entre algunas explicativas. Respecto al PCA se ha optado por elegir los primeros 8 factores que representaban el 81% de la varianza de todas las variables numéricas y binarias, de cada componente se tomo la variable con más impacto. Posteriormente se realizo el IGA y se seleccionaron las variables más influyentes.

Ya finalizando con la regresion logística se realizaron dos modelos: el primero basandose en los resultados del PCA y otro en el del IGA, siempre revisando las correlaciones para evitar colinealidad.

Modelo 1:

Variables escogidas:

`is_churned`, `reward_purchase_count_first_7days`, `first_payment_amount`, `visits_feature_2`, `given_permission_1`, `age`, `is_referral`, `payments_failed`, `number_of_cards` TRAIN:

En un primer momento se realizo con un umbral de decision de 0.5(estandar), pero como el resultado era que el predictor siempre predecia una misma categoria sesgando claramente el resultado. Se opto por reducir el umbral a 0.30. Reference Prediction 0 1 0 29665 5081 1 29754 18814

Sensibilidad: 62.97%, lo que indica que el modelo ha mejorado su capacidad para identificar clientes que hacen churn en comparación con la version con umbral 0.5. Especificidad: 61.42%, muestra un rendimiento moderado en la identificación de clientes que no hacen churn. Accuracy: 62.53%, un rendimiento moderado que refleja un balance en la clasificación de ambas clases. En este caso todas las metricas estan equilibradas. AUC: 66.79% muestra un buen rendimiento general, pero con posibles mejoras.

TEST:

Reference Prediction 0 1 0 9254 2323 1 5601 3651

Sensibilidad: 62.30% Especificidad: 61.11% Accuracy: 61.96% AUC: 66.24% El desempeño en el test es muy parecido al anterior con el train, demostrando la robustez del modelo.

Modelo 2:

Variables escogidas: `is_churned`, `payments_completed_amount_first_7days`, `reward_purchase_count_first_7days`, `first_payment_amount`, `payments_completed`,

coins_redeemed_first_7days

TRAIN: Reference Prediction 0 1 0 29038 5034 1 30381 18861

Accuracy: 57.49%, indicando que el modelo no es especialmente preciso en su clasificación. Sensibilidad: 48.87%, sugiere que el modelo tiene dificultades para identificar correctamente los clientes que hacen churn. Especificidad: 78.93%, lo que significa que el modelo clasifica con mayor precisión a los clientes que no hacen churn. AUC: 73.80%

TEST: Reference Prediction 0 1 0 7151 1248 1 7704 4726

Accuracy:57.02% Sensibilidad : 48.14% Especificidad: 79.11% AUC: 73.74%

En el segundo modelo la predicción mejora pero debido al sesgo del dataset, con una clase 0(no churn) dominante. El mejor modelo es por tanto el modelo 1 wue aunque reduzca sus resultados en multiples metricas como accuracy o AUC, mantiene un equilibrio entre la clasificacion de clases. Aunque en entropia la variable is_referral y age no tengan mucho impacto, en el modelo basado en factores son variables que favorecen una predicción equilibrada de las distintas metricas mejorando el azar. Ademas las variables referentes a pagos realizados, como first payment amount muestran su relevancia al aparecer en ambos modelos.